



# Optimiser le choix des cultures et prédire le rendement agricole

Rapport métier — Moteur de prédiction & de recommandation de  
rendement

Fatima Adda — Data Scientist, Agritech Answers

Septembre 2026

Document destiné à un public non technique : direction, équipes commerciales, agriculteurs  
partenaires.

## Résumé en un coup d'œil

J'ai construit un modèle qui estime le rendement (en tonnes par hectare) d'une parcelle agricole à partir de ses conditions (région, sol, météo, pluviométrie, température, irrigation, engrais) et de la culture choisie. Ce modèle alimente une application où l'agriculteur peut soit **obtenir une estimation de rendement** pour une culture qu'il a déjà choisie, soit **obtenir un classement indicatif des 6 cultures possibles** selon leur rendement estimé pour les conditions de sa parcelle. Ce classement porte sur le rendement, pas sur la rentabilité (prix de vente et coûts de production ne sont pas pris en compte).

|                                                            |                                                |                                              |                                                    |
|------------------------------------------------------------|------------------------------------------------|----------------------------------------------|----------------------------------------------------|
| <b>92%</b>                                                 | <b>0,50 t/ha</b>                               | <b>1 000 000</b>                             | <b>6</b>                                           |
| de la variabilité du rendement est expliquée par le modèle | d'erreur moyenne sur l'estimation de rendement | parcelles analysées pour entraîner le modèle | cultures couvertes par le moteur de recommandation |

### Le message clé pour les agriculteurs

L'analyse des données montre que, à conditions climatiques égales, **l'irrigation et l'usage d'engrais ont un impact bien plus important sur le rendement que le choix de la culture elle-même**. Une parcelle irriguée et fertilisée produit en moyenne **6,00 t/ha**, contre **3,30 t/ha** pour une parcelle ni irriguée ni fertilisée — soit près de **2 fois plus**. À l'inverse, les 6 cultures étudiées (blé, orge, coton, maïs, riz, soja) affichent des rendements moyens très proches (entre 4,64 et 4,65 t/ha) sur l'ensemble des parcelles. **Le premier levier d'action recommandé aux agriculteurs est donc l'irrigation et la fertilisation, avant le choix de la culture.**

# Comment j'ai construit ce modèle

J'ai combiné deux sources de données complémentaires :


- **Des données de parcelles** (1 million de lignes) : pour chaque parcelle, la région, le type de sol, la culture, la pluviométrie, la température, l'usage d'engrais et d'irrigation, la météo, le nombre de jours avant récolte, et le rendement réellement obtenu.
- **Des données climatiques et agronomiques mondiales** (source FAO, 1990-2013, 101 pays) : pour chaque culture, la pluviométrie moyenne, la température moyenne et l'usage de pesticides typiques dans le monde.

Ces deux sources ne pouvaient pas être combinées directement (le premier jeu de données n'indique ni le pays ni l'année). J'ai donc calculé, pour chaque culture, des **valeurs de référence mondiales** (pluviométrie, température, pesticides moyens) à partir des données FAO, puis je les ai associées à chaque parcelle selon sa culture. Cela permet de savoir si une parcelle est plus ou moins arrosée/chaude que la moyenne mondiale pour sa culture — une information utile pour le modèle. Deux cultures (orge et coton) n'ayant pas d'équivalent dans les données mondiales disponibles, je leur ai appliqué la moyenne mondiale tous produits confondus, une limitation documentée dans le notebook technique.

J'ai aussi vérifié la qualité des données : 231 valeurs de rendement négatives (impossibles physiquement, dues à du bruit de mesure/simulation) ont été ramenées à 0, et 2 310 lignes dupliquées ont été supprimées des données mondiales. Après ce nettoyage, le jeu de données final ne contient aucune valeur manquante.

# Identifier les variables qui comptent vraiment (ACP)

Pour comprendre comment les variables s'organisent, j'ai utilisé une méthode statistique appelée **analyse en composantes principales** (ACP). Elle résume les nombreuses variables décrivant une parcelle en quelques grands « axes » qui regroupent les variables liées entre elles. Le rendement, qui est ce que l'on cherche à expliquer, n'a volontairement **pas** servi à construire ces axes : il a été placé ensuite sur les graphiques, pour voir de quels axes il est proche sans qu'il influence leur construction.



Chaque flèche rouge représente une variable ; la flèche bleue en pointillés est le rendement, ajouté après coup. Plus une flèche est longue, mieux la variable est représentée sur le graphique. À gauche, les deux axes principaux : le profil mondial de la culture (horizontal) et la température (vertical). Le rendement y est à peine visible. À droite, l'axe de la pluviométrie (horizontal) et celui de l'irrigation (vertical), vers lesquels le rendement pointe nettement.

**Conclusion de cette analyse :** les axes qui résument le plus d'information sur les parcelles (le profil de la culture, la température) ne sont pas ceux qui expliquent le rendement. Le rendement est surtout lié à la **pluviométrie** de la parcelle, puis à l'**irrigation** et à l'**engrais**. Le choix de la culture compte très peu.

## Les variables clés expliquées

| Variable                     | Ce que c'est                                                                                        | Impact observé                                                                                           |
|------------------------------|-----------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|
| Engrais                      | De l'engrais est-il apporté à la parcelle ?                                                         | Très fort : +1,50 t/ha en moyenne                                                                        |
| Irrigation                   | La parcelle est-elle irriguée artificiellement ?                                                    | Très fort : +1,20 t/ha en moyenne                                                                        |
| Pluviométrie                 | Quantité de pluie reçue par la parcelle sur l'année (100 à 1 000 mm)                                | Fort : environ +0,5 t/ha par tranche de 100 mm supplémentaires                                           |
| Température                  | Température moyenne de la parcelle (15 à 40 °C)                                                     | Faible : environ +0,2 t/ha pour 10 °C de plus                                                            |
| Culture                      | Blé, orge, coton, maïs, riz ou soja                                                                 | Faible sur ce jeu de données (écart < 0,02 t/ha entre cultures)                                          |
| Type de sol                  | Sableux, argileux, limoneux, silto-argileux, tourbeux, calcaire                                     | Faible (écart < 0,01 t/ha)                                                                               |
| Jours avant récolte          | Durée du cycle de culture jusqu'à la récolte                                                        | Négligeable                                                                                              |
| Écarts à la moyenne mondiale | Différence entre la pluie (ou la température) de la parcelle et la moyenne mondiale pour sa culture | Pas d'effet propre : ils reprennent l'information de la pluviométrie et de la température de la parcelle |

## Résultats du modèle

J'ai travaillé sur un échantillon de 200 000 parcelles (sur les 1 000 000 disponibles, ce qui suffit largement pour obtenir des résultats stables). Pour que le score final soit honnête, j'ai d'abord mis de côté **20 % des parcelles** (le jeu de test), auxquelles le modèle n'a jamais eu accès pendant sa mise au point :

- **Choix du modèle** : j'ai comparé 3 approches par **validation croisée** sur les 80 % restants. Les données sont découpées en 5 parts ; chaque approche est entraînée 5 fois sur 4 parts et évaluée sur la cinquième, et l'on fait la moyenne.
- **Réglage** : j'ai ensuite testé plusieurs réglages de la meilleure approche, toujours par validation croisée.
- **Évaluation finale** : le modèle retenu est évalué **une seule fois** sur les 20 % mis de côté. Ce score n'a servi à aucun choix.

| Modèle                                               | Erreur moyenne en validation croisée (RMSE, t/ha) | Variabilité expliquée ( $R^2$ ) |
|------------------------------------------------------|---------------------------------------------------|---------------------------------|
| Régression linéaire — retenu                         | 0,499 ± 0,003                                     | 91,4 %                          |
| Forêt aléatoire (Random Forest)                      | 0,503 ± 0,003                                     | 91,2 %                          |
| Gradient Boosting                                    | 0,500 ± 0,003                                     | 91,3 %                          |
| Régression Ridge (réglage de la régression linéaire) | 0,499 ± 0,003                                     | 91,4 %                          |


**Évaluation finale sur le jeu de test (régression linéaire)** : erreur moyenne (RMSE) de **0,499 t/ha**, variabilité expliquée ( $R^2$ ) de **91,5 %**.

**Comment lire ces chiffres ?** Le RMSE indique l'erreur moyenne du modèle : une valeur de 0,50 t/ha signifie que l'estimation se trompe en moyenne de 0,50 tonne par hectare (sur des rendements qui varient entre 0 et 10 t/ha environ). Le  $R^2$  indique la part des différences de rendement entre parcelles que le modèle parvient à expliquer : environ 91 % est un très bon score. Le score final sur le test est très proche de celui de la validation croisée : le modèle se comporte aussi bien sur des parcelles qu'il n'a jamais vues.

**Quel modèle retenir ?** Les 3 approches obtiennent des scores presque identiques : la relation entre les conditions de la parcelle et le rendement est essentiellement simple (linéaire), et les modèles plus complexes n'apportent rien. Le réglage testé ensuite (la régression Ridge) **n'améliore pratiquement pas** la régression linéaire de départ. J'ai donc gardé la **régression linéaire**, le modèle le plus simple, le plus facile à expliquer et à maintenir.

## Suivi des expérimentations avec MLflow

Chaque étape a été enregistrée automatiquement dans l'outil MLflow : la validation croisée de chaque modèle comparé, les 8 réglages testés pour la régression Ridge, puis l'évaluation finale du modèle retenu sur le jeu de test. MLflow conserve l'historique complet des expérimentations (paramètres utilisés, scores obtenus, modèle associé), ce qui garantit la traçabilité et la reproductibilité de mes résultats.



The screenshot shows the MLflow Experiments page. On the left is a sidebar with navigation links: Overview, Training runs, Observability, Traces, and Sessions. The main area is titled 'Experiments' and contains a search bar and a table of experiments. The table has columns for Name, Time created, Last modified, Description, and Tags. There are two experiments listed: 'crop\_yield\_prediction' and 'Default', both created on 09/25/2026 at 01:09:02 PM.

| Name                  | Time created            | Last modified           | Description | Tags |
|-----------------------|-------------------------|-------------------------|-------------|------|
| crop_yield_prediction | 09/25/2026, 01:09:02 PM | 09/25/2026, 01:09:02 PM | -           |      |
| Default               | 09/25/2026, 01:09:02 PM | 09/25/2026, 01:09:02 PM | -           |      |

Liste des expériences MLflow : l'expérience « `crop_yield_prediction` » regroupe l'ensemble des runs de ce projet.

mlflow

3.16.0

GenAI

Model training

crop\_yield\_prediction

Experiments > crop\_yield\_prediction

Views

+ New run

crop\_yield\_predic...

Overview

Training runs

Observability

Traces

Sessions

Evaluation

Judges

Review

metrics.rmse < 1 and params.model = "tree"

All time

State: Active

Datasets


Sort: Created

Columns

Group by

|                          | Run Name                | Created        | Duration | Models | Metrics       |               |               |         | Parameters |                | Tags     |
|--------------------------|-------------------------|----------------|----------|--------|---------------|---------------|---------------|---------|------------|----------------|----------|
| <input type="checkbox"/> | final_linear_regression | 10 minutes ago | 10.0s    | model  | cv_r2_mean    | cv_rmse_mean  | cv_rmse_std   | test_r2 | test_rmse  | model_type     | stage    |
| <input type="checkbox"/> | tuning_ridge_regres...  | 11 minutes ago | 9.8s     | -      | 0.91370387... | 0.49864288... | 0.00314717... | -       | -          | linear_regr... | final_mv |
| <input type="checkbox"/> | cv_hist_gradient_bo...  | 11 minutes ago | 8.1s     | -      | 0.91328651... | 0.49984798... | 0.00309913... | -       | -          | hist_gradie... | hyperpi  |
| <input type="checkbox"/> | cv_random_forest        | 13 minutes ago | 2.3min   | -      | 0.91202072... | 0.50348293... | 0.00303153... | -       | -          | random_for...  | model_;  |
| <input type="checkbox"/> | cv_linear_regression    | 13 minutes ago | 1.8s     | -      | 0.91370387... | 0.49864289... | 0.00314716... | -       | -          | linear_regr... | model_;  |

Liste des runs : validation croisée des 3 modèles comparés (cv\_), recherche de réglages de la régression Ridge (tuning\_), puis évaluation finale unique sur le jeu de test (final\_, colonnes test\_).



The screenshot shows the MLflow Run page for the 'final\_linear\_regression' run. It provides a detailed overview of the run, including its description, metrics, parameters, and tags. The description states that the linear regression model was chosen as the best model because it achieved the lowest RMSE of validation cross (gain of 0.00000 tha, below the threshold of 0.001 tha). The metrics table shows the test\_rmse, test\_mae, test\_r2, and train\_time\_seconds. The parameters table lists the model\_type, dataset\_total\_rows, dataset\_sample\_rows, train\_rows, test\_rows, cv\_folds, and random\_seed.

| Metric             | Value               | Models |
|--------------------|---------------------|--------|
| test_rmse          | 0.49871759898528    | model  |
| test_mae           | 0.39799880011735506 | model  |
| test_r2            | 0.9150689344128208  | model  |
| train_time_seconds | 0.3236856460571289  | model  |

| Parameter           | Value             |
|---------------------|-------------------|
| model_type          | linear_regression |
| dataset_total_rows  | 1000000           |
| dataset_sample_rows | 200000            |
| train_rows          | 160000            |
| test_rows           | 40000             |
| cv_folds            | 5                 |
| random_seed         | 42                |

Détail du run final : le modèle retenu (régression linéaire), ses scores sur le jeu de test et la justification du choix.

# Recommandations agronomiques

- **Prioriser l'irrigation et la fertilisation.** C'est le levier le plus efficace identifié dans les données : le gain moyen observé (+2,70 t/ha entre le meilleur et le pire scénario) dépasse largement les écarts liés au choix de la culture ou au type de sol.
- **Utiliser l'outil de recommandation comme aide à la décision, pas comme verdict unique.** Sur les données actuelles, les 6 cultures affichent des rendements estimés très proches, souvent à quelques centièmes de tonne par hectare, alors que l'erreur moyenne du modèle est d'environ 0,50 t/ha. Le classement ne permet donc généralement pas d'affirmer qu'une culture donnera un meilleur rendement qu'une autre : l'application le signale explicitement lorsque les écarts sont plus faibles que cette erreur. Le choix de culture doit aussi intégrer d'autres critères non couverts ici (prix de vente, coûts de production, rotation des cultures, débouchés commerciaux).
- **Tenir compte de la pluviométrie.** C'est le facteur naturel le plus lié au rendement (environ +0,5 t/ha par tranche de 100 mm de pluie par an). Sur les parcelles peu arrosées, l'irrigation est d'autant plus utile pour compenser.
- **Enrichir les données à l'avenir** avec des quantités réelles de pesticides et d'engrais par parcelle (plutôt que des indicateurs oui/non), ainsi que la localisation géographique précise, pour affiner encore les recommandations.

## Limites à connaître

- Les données de pesticides mondiales sont des totaux nationaux (tous produits confondus), pas des quantités spécifiques à chaque culture.
- L'orge et le coton n'ayant pas de correspondance directe dans les données climatiques mondiales utilisées, une moyenne globale leur a été appliquée par défaut.
- Le modèle a été entraîné sur un échantillon de 200 000 parcelles simulées ; une validation sur des données réelles de terrain reste recommandée avant un déploiement à grande échelle.
- La mise à jour de l'application n'est pas encore entièrement automatique : le réentraînement du modèle se lance à la main, et l'interface en ligne est mise à jour sans attendre la réussite des tests automatiques (l'API, elle, les attend). Le détail figure dans la documentation technique du projet.

Pour toute question sur ce rapport ou sur l'application, je reste disponible.