



Optimiser le choix des cultures et prédire le rendement agricole

Rapport métier — Moteur de prédiction & de recommandation de rendement

Fatima Adda — Data Scientist, Agritech Answers

Septembre 2026

Document destiné à un public non technique : direction, équipes commerciales, agriculteurs partenaires.

Résumé en un coup d'œil

J'ai construit un modèle qui estime le rendement (en tonnes par hectare) d'une parcelle agricole à partir de ses conditions (région, sol, météo, pluviométrie, température, irrigation, engrais) et de la culture choisie. Ce modèle alimente une application où l'agriculteur peut soit **obtenir une estimation de rendement** pour une culture qu'il a déjà choisie, soit **obtenir un classement indicatif des 6 cultures possibles** selon leur rendement estimé pour les conditions de sa parcelle. Ce classement porte sur le rendement, pas sur la rentabilité (prix de vente et coûts de production ne sont pas pris en compte).

92%	0,50 t/ha	1 000 000	6
de la variabilité du rendement est expliquée par le modèle	d'erreur moyenne sur l'estimation de rendement	parcelles analysées pour entraîner le modèle	cultures couvertes par le moteur de recommandation

Le message clé pour les agriculteurs

L'analyse des données montre que, à conditions climatiques égales, **l'irrigation et l'usage d'engrais ont un impact bien plus important sur le rendement que le choix de la culture elle-même**. Une parcelle irriguée et fertilisée produit en moyenne **6,00 t/ha**, contre **3,30 t/ha** pour une parcelle ni irriguée ni fertilisée — soit près de **2 fois plus**. À l'inverse, les 6 cultures étudiées (blé, orge, coton, maïs, riz, soja) affichent des rendements moyens très proches (entre 4,64 et 4,65 t/ha) sur l'ensemble des parcelles. **Le premier levier d'action recommandé aux agriculteurs est donc l'irrigation et la fertilisation, avant le choix de la culture.**

Comment j'ai construit ce modèle

J'ai combiné deux sources de données complémentaires :


- **Des données de parcelles** (1 million de lignes) : pour chaque parcelle, la région, le type de sol, la culture, la pluviométrie, la température, l'usage d'engrais et d'irrigation, la météo, le nombre de jours avant récolte, et le rendement réellement obtenu.
- **Des données climatiques et agronomiques mondiales** (source FAO, 1990-2013, 101 pays) : pour chaque culture, la pluviométrie moyenne, la température moyenne et l'usage de pesticides typiques dans le monde.

Ces deux sources ne pouvaient pas être combinées directement (le premier jeu de données n'indique ni le pays ni l'année). J'ai donc calculé, pour chaque culture, des **valeurs de référence mondiales** (pluviométrie, température, pesticides moyens) à partir des données FAO, puis je les ai associées à chaque parcelle selon sa culture. Cela permet de savoir si une parcelle est plus ou moins arrosée/chaude que la moyenne mondiale pour sa culture — une information utile pour le modèle. Deux cultures (orge et coton) n'ayant pas d'équivalent dans les données mondiales disponibles, je leur ai appliqué la moyenne mondiale tous produits confondus, une limitation documentée dans le notebook technique.

J'ai aussi vérifié la qualité des données : 231 valeurs de rendement négatives (impossibles physiquement, dues à du bruit de mesure/simulation) ont été ramenées à 0, et 2 310 lignes dupliquées ont été supprimées des données mondiales. Après ce nettoyage, le jeu de données final ne contient aucune valeur manquante.

Identifier les variables qui comptent vraiment (ACP)

Pour savoir quelles variables influencent le plus le rendement, j'ai utilisé une méthode statistique appelée **analyse en composantes principales** (ACP). Le principe : elle regarde toutes les variables en même temps et identifie celles qui expliquent le plus les différences observées entre les parcelles, en éliminant les redondances.



À gauche : le « cercle des corrélations », qui montre comment les variables se regroupent. À droite : la part de variabilité expliquée par chaque axe (les 2 premiers axes suffisent à résumer une grande partie de l'information).

Conclusion de cette analyse : le rendement ne dépend pas d'une seule variable dominante, mais d'une combinaison de facteurs — ce qui justifie l'usage d'un modèle statistique plutôt que d'une règle simple, et confirme l'importance de variables comme l'irrigation, l'engrais et le type de sol.

Les variables clés expliquées

Variable	Ce que c'est	Impact observé
Irrigation	La parcelle est-elle irriguée artificiellement ?	Très fort : +1,20 t/ha en moyenne
Engrais	De l'engrais est-il apporté à la parcelle ?	Très fort : +1,50 t/ha en moyenne
Culture	Blé, orge, coton, maïs, riz ou soja	Faible sur ce jeu de données (écart < 0,02 t/ha entre cultures)
Type de sol	Sableux, argileux, limoneux, silto-argileux, tourbeux, calcaire	Faible (écart < 0,01 t/ha)
Écart de pluviométrie	Différence entre la pluviométrie de la parcelle et la moyenne mondiale pour sa culture	Modéré, capté par le modèle
Écart de température	Différence entre la température de la parcelle et la moyenne mondiale pour sa culture	Modéré, capté par le modèle
Jours avant récolte	Durée du cycle de culture jusqu'à la récolte	Modéré

Résultats du modèle

J'ai comparé 3 approches de modélisation avant d'optimiser la meilleure, en utilisant un échantillon de 200 000 parcelles (sur les 1 000 000 disponibles, ce qui est largement suffisant pour obtenir des résultats stables et fiables) :

Modèle	Erreur moyenne (RMSE, t/ha)	Variabilité expliquée (R^2)
Régression linéaire	0,499	91,5 %
Forêt aléatoire (Random Forest)	0,504	91,3 %
Gradient Boosting	0,500	91,5 %
Régression Ridge optimisée (retenue)	0,499	91,5 %

Comment lire ces chiffres ? Le RMSE indique l'erreur moyenne du modèle : une valeur de 0,50 t/ha signifie que l'estimation se trompe en moyenne de 0,50 tonne par hectare (sur des rendements qui varient entre 0 et 10 t/ha environ). Le R^2 indique la part de variabilité du rendement que le modèle parvient à expliquer : 91,5 % est un très bon score. Les 3 approches obtiennent des résultats très proches, ce qui indique que la relation entre les conditions de parcelle et le rendement est majoritairement simple (linéaire) sur ce jeu de données — j'ai donc retenu et optimisé la régression Ridge, plus simple et donc plus facile à interpréter et à maintenir, pour une précision équivalente.

Suivi des expérimentations avec MLflow

Chaque modèle entraîné et chaque combinaison de paramètres testée (8 configurations différentes pour l'optimisation) a été enregistré automatiquement dans l'outil MLflow, qui conserve l'historique complet des expérimentations : paramètres utilisés, métriques obtenues, et modèle associé. Cela garantit la traçabilité et la reproductibilité de mes résultats.

mlflow

3.16.0

GenAI

Model training

Home

Experiments

Prompts

MCP registryBeta

AI GatewayNew

Docs

Settings

Welcome to MLflow

Information about UI telemetry

MLflow collects usage data to improve the product. To confirm your preferences, please visit the settings page in the navigation sidebar. To learn more about what data is collected, please visit the [documentation](#).

Getting Started

New to MLflow?

Explore MLflow's core features with pre-populated sample data including traces, evaluations, and prompts.

Start Demo

Tracing

Capture and debug LLM interactions and agent workflows.

Evaluation

Measure and compare LLM quality with built-in and custom...

Prompts

Version control and manage prompts with aliases across...

AI Gateway

Unified API for multiple LLM providers with rate limiting.

Recent Experiments

View all

	Name	Time created	Last modified	Description	Tags
	crop_yield_prediction	09/16/2026, 07:22:32 PM	09/16/2026, 07:22:32 PM	-	
	Default	09/16/2026, 07:22:32 PM	09/16/2026, 07:22:32 PM	-	

Page d'accueil MLflow : l'expérience « crop_yield_prediction » regroupe l'ensemble des runs de ce projet.

mlflow

3.16.0

GenAI

Model training

crop_yield_prediction

Runs

Models

Traces

Model registry

Docs

Settings

Experiments > crop_yield_prediction

Runs

metrics.rmse < 1 and params.model = "tree"

All time

State: Active

Datasets

Sort: Created

Columns

+ New run

Group by

	Run Name	Created	Dataset	Duration	Source	Models	Metrics	Params		
							cv_neg_rmse	mae	r2	model_
	tuning_ridge_regres...	3 minutes ago	-	16.4s	train.py	model	0.39799960...	0.91506888...	ridge_re	
	baseline_hist_gradi...	3 minutes ago	-	2.5s	train.py	-	0.39897038...	0.91460888...	hist_gra	
	baseline_random_to...	4 minutes ago	-	39.5s	train.py	-	0.40163038...	0.91339436...	random	
	baseline_linear_regr...	4 minutes ago	-	0.6s	train.py	-	0.39799880...	0.91506893...	linear_r	

12 matching runs

Liste des runs d'entraînement avec leurs métriques (MAE, R^2) et le type de modèle testé.

mf

flow

3.16.0

GenAI

Model training

←

crop_yield_predic...

Overview

Training runs

Observability

Traces

Sessions

Evaluation

Judges

Review

Datasets

Evaluation runs

Prompts & versions

Playground

Prompts

Agent versions

AI Gateway

New

Docs

Settings

crop_yield_prediction > Runs >

tuning_ridge_regression

Overview

Model metrics

System metrics

Traces

Artifacts

Description

Meilleur modèle après RandomizedSearchCV (8 configurations x 3 folds) sur ridge_regression.

Metrics (4)

Search metrics

Metric	Value	Models
rms	0.4987183172292971	model
mae	0.39799960139051266	model
r2	0.9150686897507445	model
tuning_time_seconds	8.524596214294434	model

Parameters (6)

Search parameters

Parameter	Value
model_type	ridge_regression
model_solver	cholesky
model_alpha	1.0
dataset_total_rows	1000000
dataset_sample_rows	200000
random_seed	42

Logged models (1)

Model attributes

Type	Step	Model name	Status	Created	Registered models
Output	0	model	Ready	3 minutes ago	-

About this run

Created at

09/16/2026, 07:23:19 PM

Created by

root

Experiment ID

1

Status

Finished

Run ID

clcf72ecf220f484cb05a6a011e82f3ad

Duration

16.4s

Child runs

candidate_7, candidate_6, candidate_5, candidate_4, candidate_3, candidate_2, candidate_1, candidate_0

Source

train.py

Registered prompts

-

Datasets

None

Tags

stage: best_model

Registered models

None

Détail du meilleur run : métriques, paramètres optimaux retenus (alpha=1,0, solveur cholesky) et modèle enregistré.

Recommandations agronomiques

- **Prioriser l'irrigation et la fertilisation.** C'est le levier le plus efficace identifié dans les données : le gain moyen observé (+2,70 t/ha entre le meilleur et le pire scénario) dépasse largement les écarts liés au choix de la culture ou au type de sol.
- **Utiliser l'outil de recommandation comme aide à la décision, pas comme verdict unique.** Sur les données actuelles, les 6 cultures affichent des rendements estimés très proches, souvent à quelques centièmes de tonne par hectare, alors que l'erreur moyenne du modèle est d'environ 0,50 t/ha. Le classement ne permet donc généralement pas d'affirmer qu'une culture donnera un meilleur rendement qu'une autre : l'application le signale explicitement lorsque les écarts sont plus faibles que cette erreur. Le choix de culture doit aussi intégrer d'autres critères non couverts ici (prix de vente, coûts de production, rotation des cultures, débouchés commerciaux).
- **Surveiller l'écart à la normale climatique de la culture** (pluviométrie et température par rapport à la moyenne mondiale) : ces écarts, calculés automatiquement par l'outil, sont des indicateurs utiles pour anticiper un risque de sous-rendement.
- **Enrichir les données à l'avenir** avec des quantités réelles de pesticides et d'engrais par parcelle (plutôt que des indicateurs oui/non), ainsi que la localisation géographique précise, pour affiner encore les recommandations.

Limites à connaître

- Les données de pesticides mondiales sont des totaux nationaux (tous produits confondus), pas des quantités spécifiques à chaque culture.
- L'orge et le coton n'ayant pas de correspondance directe dans les données climatiques mondiales utilisées, une moyenne globale leur a été appliquée par défaut.
- Le modèle a été entraîné sur un échantillon de 200 000 parcelles simulées ; une validation sur des données réelles de terrain reste recommandée avant un déploiement à grande échelle.

Pour toute question sur ce rapport ou sur l'application, je reste disponible.